

❑ PLAN DE IMPLEMENTACIÓN - GOVERNANCE DE ADAPTACIÓN DE MODELOS

Versión: 1.0

Fecha Creación: Octubre 2025

Estado: PENDIENTE (Post-Demo)

Prioridad: ALTA - Feature estratégico para V1.1.0

❑ OBJETIVO

Implementar el sistema completo de governance para adaptación de modelos (Adapters, Merge, Quantization, Fine-Tuning) que **posiciona a CodeflowX como líder en sostenibilidad y eficiencia** en IA.

Mensaje Estratégico:

“¿Por qué entrenar desde cero cuando puedes adaptar? 3M de modelos disponibles, aprovéchalos de forma sostenible.”

❑ ROADMAP POST-DEMO

FASE 1: Base de Datos y Backend (Semana 1-2)

1.1 Extensiones SQL

- ❑ Ejecutar 01_model_adaptation_fields.sql
 - Añade campos a MODMODELS para adaptación
 - Crea FK self-referencing IDMODBASEMODEL
 - Crea vista recursiva V_MODEL_LINEAGE_TREE
- ❑ Ejecutar 02_model_adaptation_workflows.sql
 - Crea tabla MODADAPTATIONSTRATEGIES
 - Crea vista V_ADAPTATION_STRATEGIES_DASHBOARD
 - Inserta 5 nuevos procesos BPMN

Ubicación Archivos:

```
/mnt/c/Users/ManuelGonzalez/git/codeflowx-  
nocode/sources/sql/extensions/  
├─ 01_model_adaptation_fields.sql  
└─ 02_model_adaptation_workflows.sql
```

1.2 Generación de Entidades JPA

- ❑ Regenerar entidad Model con nuevos campos:

**MODISADAPTER, MODISFINETUNED, MODISQUANTIZED, MODISMERGED,
MODADAPTERCONFIG, MODFINETUNINGCONFIG, MODQUANTIZATIONCONFIG,
MODMERGECONFIG, MODADAPTATIONSTRATEGY, MODADAPTATIONMETADATA,
IDMODBASEMODEL**

- ☐ Generar entidad ModelAdaptationStrategy
- ☐ Regenerar vistas: V_MODEL_LINEAGE_TREE,
V_ADAPTATION_STRATEGIES_DASHBOARD

Comando:

```
cd /mnt/c/Users/ManuelGonzalez/git/codeflowx-nocode
python src/generator.py --json
sources/json/tables/MODADAPTATIONSTRATEGIES.json
```

1.3 BusinessService

- ☐ Verificar métodos existentes en ModelBusinessService
- ☐ Añadir método findModelLineage(modelId) (usa view recursiva)
- ☐ Añadir método findAdaptationStrategies() (usa view dashboard)

FASE 2: Procesos BPMN (Semana 3-4)

2.1 Nuevos Procesos BPMN (5 procesos)

Prioridad ALTA: 1. [] **adaptation-strategy-recommendation-v1** - IA recomienda mejor estrategia (Adapter/Merge/Quantization/Fine-Tuning) - Input: Caso de uso, presupuesto, tiempo, hardware - Output: Estrategia recomendada + justificación - Delegate: RecommendAdaptationStrategyDelegate - Python Service: adaptation_strategy_recommender.py

2. ☐ **adapter-creation-approval-v1**
- Aprobación de creación de Adapters (LoRA/QLoRA)
 - Validación: Costo, tiempo, CO2 vs fine-tuning completo
 - Drools: adapter-approval-scoring.drl (9 reglas)
 - 85% automatizado

Prioridad MEDIA: 3. [] **model-merge-approval-v1** - Aprobación de fusión de modelos - Validación: Compatibilidad, licencias, performance esperado

4. ☐ **model-quantization-approval-v1**
- Aprobación de cuantificación de modelos
 - Validación: Hardware target, precisión aceptable

Prioridad BAJA (Restringido): 5. [] **finetuning-approval-v1** - Proceso restrictivo que requiere justificación - ¿Por qué no usar Adapter/Merge/Quantization? - Validación estricta de necesidad

2.2 Archivos BPMN

Ubicación:

```
suinsit.nova.web/src/main/resources/processes/
├─ adaptation-strategy-recommendation-v1.bpmn
├─ adapter-creation-approval-v1.bpmn
├─ model-merge-approval-v1.bpmn
├─ model-quantization-approval-v1.bpmn
└─ finetuning-approval-v1.bpmn
```

2.3 Delegates Java

Crear: - RecommendAdaptationStrategyDelegate.java -
ValidateAdapterConfigDelegate.java -
ValidateMergeCompatibilityDelegate.java -
ValidateQuantizationPrecisionDelegate.java -
JustifyFineTuningDelegate.java

Ubicación:

suinsit.nova.web/src/main/java/com/codeflowx/govern/workflow/delegate

2.4 Drools Rules

Crear: - adapter-approval-scoring.drl - merge-approval-scoring.drl -
quantization-approval-scoring.drl - finetuning-justification-
scoring.drl

Ubicación:

suinsit.nova.web/src/main/resources/rules/

FASE 3: Python ML Services (Semana 5)

3.1 Servicio de Recomendación de Estrategia

Archivo: adaptation_strategy_recommender.py

Input:

```
{
  "use_case": "chatbot_customer_support",
  "dataset_size": 10000,
  "budget_usd": 500,
  "time_days": 7,
  "hardware_available": ["cpu", "gpu_t4"],
  "target_performance": 0.85,
  "priority": "cost" # cost, time, co2, performance
}
```

Output:

```
{
  "recommended_strategy": "ADAPTER_LORA",
  "confidence": 0.92,
  "justification": "...",
  "alternatives": [
    {"strategy": "QUANTIZATION", "score": 0.78},
    {"strategy": "FINE_TUNING", "score": 0.45}
  ],
  "estimated_cost": 150,
  "estimated_time_hours": 24,
  "estimated_co2_kg": 2.5
}
```

Lógica: - Scoring multi-criterio (costo, tiempo, CO2, performance) -
Reglas heurísticas + ML (opcional) - Prioriza Adapters > Quantization
> Merge > Fine-Tuning

3.2 Validadores

- validate_adapter_config.py - Valida configuración LoRA/QLoRA
 - validate_merge_compatibility.py - Valida compatibilidad de modelos para merge
 - validate_quantization_precision.py - Estima pérdida de precisión
-

FASE 4: ViewModels y Pantallas ZUL (Semana 6-7)

4.1 ViewModels Nuevos

- ☐ AdaptationStrategyRecommendationViewModel.java
- ☐ AdapterCreationApprovalViewModel.java
- ☐ ModelMergeApprovalViewModel.java
- ☐ ModelQuantizationApprovalViewModel.java
- ☐ FineTuningApprovalViewModel.java
- ☐ ModelLineageOverviewViewModel.java
- ☐ AdaptationStrategiesDashboardViewModel.java

4.2 Pantallas ZUL Nuevas

- ☐ adaptation-strategy-recommendation-form.zul
- ☐ adapter-creation-approval-form.zul
- ☐ model-merge-approval-form.zul
- ☐ model-quantization-approval-form.zul
- ☐ finetuning-approval-form.zul
- ☐ model-lineage-tree.zul (Visualización árbol de linaje)
- ☐ adaptation-strategies-dashboard.zul

4.3 Dashboard de Linaje de Modelos

Visualización Tipo Árbol:

- ☐ llama-2-7b (Base Model)
 - ☐ llama-2-7b-customer-support-adapter (LoRA)
 - ☐ llama-2-7b-cs-spanish-adapter (LoRA sobre LoRA)
 - ☐ llama-2-7b-4bit (Quantization)
 - ☐ llama-2-7b-customer-merged (Merge con otro)

Métricas por Nodo: - Costo creación - CO2 emitido - Performance actual - Estado (activo/deprecated)

FASE 5: Integración con Model Registry (Semana 8)

5.1 Actualizar Model Registry

- ☐ Añadir columna "Adaptation Strategy" en listado de modelos
- ☐ Badge visual: ☐ Adapter, ☐ Merge, ☐ Quantization, ☐ Fine-Tuned
- ☐ Filtro por estrategia de adaptación
- ☐ Columna "Base Model" con link al modelo original

5.2 Model Detail View

- ☐ Sección "Adaptation Info" con:
 - Estrategia utilizada
 - Modelo base (si aplica)
 - Configuración de adaptación (JSON)
 - Métricas de eficiencia (costo, CO2, tiempo)

- Link a proceso BPMN de aprobación

FASE 6: Dashboards Ejecutivos (Semana 9)

6.1 Dashboard “Sustainability Impact”

Métricas: - CO2 ahorrado vs fine-tuning completo - Costo total ahorrado - Tiempo total ahorrado - Modelos adaptados vs entrenados desde cero

Gráficos: - Pie chart: Distribución de estrategias (Adapter 60%, Quantization 25%, etc.) - Line chart: Evolución CO2 mensual - Bar chart: Ahorro por estrategia

6.2 Dashboard “Adaptation Strategies”

- Vista V_ADAPTATION_STRATEGIES_DASHBOARD (ya creada en SQL)
- Tabla comparativa de estrategias
- Recomendación automática de estrategia más usada

FASE 7: Testing y Documentación (Semana 10)

7.1 Testing

- ☐ Unit tests de Delegates
- ☐ Integration tests de procesos BPMN
- ☐ Test de validadores Python
- ☐ Test de ViewModels
- ☐ Test end-to-end de flujo completo

7.2 Documentación

- ☐ Documentación técnica de procesos BPMN
- ☐ Guía de usuario para ML Engineers
- ☐ Runbook operacional
- ☐ Actualizar documentación comercial

☐ MÉTRICAS DE ÉXITO

KPIs a Medir Post-Implementación:

Métrica	Target
% Modelos adaptados vs entrenados desde cero	>70%
CO2 reducido (kg)	>1000 kg/mes
Costo ahorrado (USD)	>\$5000/mes
Tiempo ahorrado (horas)	>500 h/mes
% Uso de Adapters	>60%
% Uso de Quantization	>25%
% Fine-Tuning (restrictivo)	<10%

□ DIFERENCIADORES COMPETITIVOS

Mensaje Comercial Post-Implementación:

“CodeflowX es la ÚNICA plataforma de AI Governance que prioriza la **sostenibilidad** y **eficiencia** mediante:

□ **Recomendación Inteligente de Estrategia** - IA decide la mejor forma de adaptar □ **Governance de Adaptación** - Procesos BPMN certificables □ **Linaje de Modelos** - Trazabilidad completa de origen □ **Métricas de Sostenibilidad** - CO2, costo, tiempo medidos □ **Proceso Restrictivo para Fine-Tuning** - Requiere justificación explícita

Resultado: 70% reducción en CO2 + 60% reducción en costos + Compliance garantizado”

□ CONTACTO PARA IMPLEMENTACIÓN

Equipo Técnico: - Backend Lead: [Asignar] - Frontend Lead: [Asignar] - ML/Python Lead: [Asignar] - QA Lead: [Asignar]

Timeline: 10 semanas (2.5 meses)
Esfuerzo Estimado: 400-500 horas
Prioridad: ALTA - Feature estratégico V1.1.0

Estado: □ PENDIENTE - Ejecutar post-demo
Próximo Paso: Aprobar roadmap y asignar equipo